

Econometría del modelo de velocidad de arriendo

Especificación, derivadas e inventario de sesgos

Proyecto *Predicción de tiempo de arriendo*
Assetplan

Septiembre de 2026

Resumen

Nota metodológica del modelo de duración de vacancia de unidades de arriendo. Se presenta la especificación *accelerated failure time* log-normal, se derivan explícitamente los efectos marginales sobre días y sobre la probabilidad publicada, y se documenta el inventario completo de sesgos: siete corregidos dentro del modelo y tres que quedan vivos. Los dos sesgos vivos que afectan al coeficiente de precio atenúan hacia cero, de modo que la estimación es plausiblemente una cota inferior del efecto del sobreprecio. Muestra de estimación: $n = 3,889$ unidades en 14 cohortes mensuales, con $\hat{\sigma} = 1,335$.

Índice

1. Notación	2
2. El objeto de estimación: la tasa, no el promedio	2
3. Especificación: AFT log-normal	2
4. Efectos marginales	3
4.1. Sobre los días	3
4.2. Sobre la probabilidad publicada	3
4.3. Sobre la dispersión	4
5. Verosimilitud censurada y ecuaciones de score	4
6. Sesgo I: censura	4
7. Sesgo II: riesgo competitivo	5
8. El precio de referencia y sus dos sesgos	5
8.1. Regresor generado	6
8.2. Identificación de $\text{Var}(\xi)$ y corrección de la atenuación	6
8.3. Endogeneidad: el sesgo que no se corrige	7
9. Sesgo IV: codificación del efecto de edificio	8
10. Sesgo V: el esquema de validación	8
11. Calibración	8
12. El techo estocástico	9

13. Inventario de sesgos	10
14. Síntesis	10

1. Notación

Símbolo	Significado
T	días desde LPA (<i>lista para arrendar</i>) hasta el cierre comercial
t_i	tiempo observado, $\min(T_i, c_i)$ con c_i el seguimiento disponible
d_i	indicador de evento: 1 si se observó el arriendo, 0 si está censurada
x_i	vector de atributos conocidos el día de la publicación
g_i	<i>gap</i> de precio: $\log(\text{precio}) - \log(\text{precio esperado})$
$S(t)$	función de supervivencia, $\mathbb{P}(T > t)$
$h(t)$	tasa de riesgo (<i>hazard</i>)
ϕ, Φ	densidad y acumulada de la normal estándar
$\lambda(z)$	razón de Mills inversa, $\phi(z)/(1 - \Phi(z))$
σ	desviación estándar del logaritmo de la duración

2. El objeto de estimación: la tasa, no el promedio

El objeto natural no es $\mathbb{E}[T]$ sino la **tasa de riesgo**: la velocidad instantánea a la que una unidad vacante se coloca, condicional a seguir vacante,

$$h(t | x) = \lim_{\Delta \rightarrow 0} \frac{\mathbb{P}(t \leq T < t + \Delta | T \geq t, x)}{\Delta} = \frac{f(t | x)}{S(t | x)} = -\frac{d}{dt} \log S(t | x). \quad (1)$$

Hay dos razones, ambas estructurales. La primera es que el 20,0% de la muestra no tiene desenlace: al cierre de los datos seguía vacante. Un promedio calculado sobre las unidades que sí cerraron no estima $\mathbb{E}[T]$ sino $\mathbb{E}[T | T \leq c]$, que es una cantidad distinta. La segunda es que la tasa es lo que la operación decide: cuánta atención asignar hoy a una unidad depende de la probabilidad de que se coloque en los próximos días, no del promedio histórico.

Integrando (1) se recupera todo lo demás, $S(t) = \exp(-\int_0^t h(u) du)$, y la probabilidad de colocarse antes de un horizonte h es $1 - S(h)$.

3. Especificación: AFT log-normal

La especificación es una regresión lineal sobre el logaritmo de la duración —*accelerated failure time*, porque los regresores aceleran o frenan el reloj del proceso—,

$$\log T_i = x_i' \beta + \sigma \varepsilon_i, \quad \varepsilon_i \sim N(0, 1), \quad (2)$$

de donde $\log T | x \sim N(x' \beta, \sigma^2)$. Las tres cantidades que el modelo entrega salen de una única estimación:

$$S(t | x) = 1 - \Phi(z), \quad \mathbb{P}(T \leq h | x) = \Phi\left(\frac{\log h - x' \beta}{\sigma}\right), \quad z \equiv \frac{\log t - x' \beta}{\sigma}. \quad (3)$$

Esa es la ventaja práctica sobre un modelo binario: una regresión logística ajustada sobre “¿se arrendó en 20 días?” no contiene información sobre los 30 días. El AFT devuelve la curva completa para cualquier horizonte sin reajustar.

Observación 1 (Por qué log-normal y no Weibull). La distribución Weibull impone una tasa de riesgo monótona: siempre creciente o siempre decreciente. La evidencia empírica lo contradice: Gdakowicz, Putek-Szeląg y Bas [8] documentan una caída pronunciada de la tasa después de 7–8 semanas en el mercado polaco de arriendo. La log-normal admite una tasa no monótona, que es la forma esperada cuando la demanda inicial se agota. Un modelo de riesgo en tiempo discreto con la forma base completamente libre —*spline* lineal por tramos en $\log(\text{semana})$, siguiendo a Deng, Gabriel y Nothhaft [2]— alcanza esencialmente el mismo error integrado: 0,195 contra 0,196.

4. Efectos marginales

Hay tres derivadas y responden preguntas distintas.

4.1. Sobre los días

Directamente de (2), puesto que $\mathbb{E}[\log T \mid x] = x' \beta$:

$$\frac{\partial \mathbb{E}[\log T \mid x]}{\partial x_k} = \beta_k, \quad T_{\text{med}}(x) = e^{x' \beta} \implies \frac{\partial T_{\text{med}}}{\partial x_k} = \beta_k T_{\text{med}}. \quad (4)$$

Un coeficiente es una **semi-elasticidad**: $\beta_k = -0,10$ corresponde a aproximadamente un 10 % menos de días. El efecto *en días* no es constante, sino proporcional al nivel: los mismos $-0,10$ equivalen a 3 días en una unidad que se coloca en 30 y a 9 días en una que tarda 90. Comunicar “ahorro de días” sin declarar la base es engañoso.

Cuando el regresor ya está en logaritmos —como el precio— el coeficiente es una **elasticidad**: variación porcentual de los días ante una variación porcentual del precio.

4.2. Sobre la probabilidad publicada

El entregable no son días sino $\mathbb{P}(T \leq h)$. Derivando (3) por la regla de la cadena, con $\partial z / \partial x_k = -\beta_k / \sigma$:

$$\boxed{\frac{\partial \mathbb{P}(T \leq h \mid x)}{\partial x_k} = \phi(z) \frac{\partial z}{\partial x_k} = -\frac{\phi(z) \beta_k}{\sigma}} \quad (5)$$

Resultado 1 (Dónde tiene efecto la palanca de precio). El efecto marginal no es constante: lo modula $\phi(z)$, que alcanza su máximo en $z = 0$, es decir cuando la mediana predicha de la unidad coincide exactamente con el horizonte de reporte. Una rebaja de precio mueve mucho la probabilidad de colocar en 20 días para una unidad que el modelo estima en torno a 20 días, y casi nada para una unidad que el modelo estima en 5 o en 90: en los extremos $\phi(z)$ se aplasta.

La implicación operativa es contraintuitiva: **la intervención de precio rinde en el centro de la distribución, no en la cola**. El decil más lento está tan lejos del horizonte que el precio no lo rescata; allí el problema es de otra naturaleza.

4.3. Sobre la dispersión

$$\frac{\partial \mathbb{P}(T \leq h \mid x)}{\partial \sigma} = \phi(z) \frac{z}{\sigma}. \quad (6)$$

Un σ mayor empuja todas las probabilidades hacia $1/2$ y aplanas las diferencias entre unidades. Con $\hat{\sigma} = 1,335$ el intervalo de una desviación estándar corresponde a un factor $e^{1,335} \approx 3,8$ en días. Ese número explica por completo que el error absoluto mediano en días sea de aproximadamente 20 contra una mediana de 29, y es la razón por la cual el entregable es una probabilidad y un decil, nunca un día puntual.

5. Verosimilitud censurada y ecuaciones de score

Una unidad arrendada aporta su densidad; una unidad todavía vacante aporta la supervivencia, es decir la información “tardó *al menos* esto”:

$$\ell(\beta, \sigma) = \sum_i d_i [\log \phi(z_i) - \log \sigma] + (1 - d_i) \log(1 - \Phi(z_i)), \quad z_i = \frac{\log t_i - x'_i \beta}{\sigma}. \quad (7)$$

Derivando, y usando $\partial z_i / \partial \beta = -x_i / \sigma$, $\partial z_i / \partial \sigma = -z_i / \sigma$, junto con $\frac{d}{dz} \log \phi(z) = -z$ y $\frac{d}{dz} \log(1 - \Phi(z)) = -\lambda(z)$:

$$\frac{\partial \ell}{\partial \beta} = \frac{1}{\sigma} \sum_i \left[d_i z_i + (1 - d_i) \lambda(z_i) \right] x_i, \quad (8)$$

$$\frac{\partial \ell}{\partial \sigma} = \frac{1}{\sigma} \sum_i \left[d_i (z_i^2 - 1) + (1 - d_i) z_i \lambda(z_i) \right]. \quad (9)$$

Resultado 2 (Qué aporta cada observación). Una observación con evento contribuye su residuo estandarizado z_i , igual que en mínimos cuadrados. Una observación censurada contribuye $\lambda(z_i)$, que es el **residuo esperado condicional a superar el umbral observado**. La censura no se descarta: se imputa con la esperanza condicional que impone el propio modelo. Esa es toda la diferencia respecto de descartar las 780 observaciones censuradas.

Observación 2 (Penalización *ridge*). Lo que se maximiza en la práctica es $\ell(\beta, \sigma) - \lambda \|\beta_{-0}\|^2$, de modo que (8) incorpora un término adicional $-2\lambda\beta$. Eso introduce sesgo hacia cero de manera deliberada, a cambio de varianza. Con 43 parámetros y aproximadamente 945 eventos el número de eventos por parámetro es 22, holgado según los criterios habituales; el *shrinkage* responde a la dispersión del diseño —edificios con pocas unidades— más que a escasez de muestra. Sigue la recomendación de van Smeden *et al.* [17].

6. Sesgo I: censura

Es el sesgo de mayor magnitud y el modelo lo corrige. Supóngase el procedimiento intuitivo: regresión por mínimos cuadrados de $\log T$ sobre las unidades ya arrendadas. Eso estima $\mathbb{E}[\log T \mid x, T \leq c]$. Para una normal truncada por arriba, con $a \equiv (\log c - x' \beta) / \sigma$ y usando $\mathbb{E}[Z \mid Z \leq a] = -\phi(a) / \Phi(a)$ para $Z \sim N(0, 1)$:

$$\mathbb{E}[\log T \mid x, T \leq c] = x' \beta - \sigma \frac{\phi(a)}{\Phi(a)}. \quad (10)$$

El término omitido, $-\sigma\phi(a)/\Phi(a)$, es siempre negativo: el estimador ingenuo **siempre predice más rápido de lo real**. Pero lo grave no es el signo sino que a depende de $x'\beta$. El término omitido está correlacionado con los regresores, de modo que no es un desplazamiento del intercepto que pueda ignorarse: **sesga todo el vector β** .

El problema se agrava justamente donde más importa. Cuanto más corto el seguimiento —las cohortes recientes— menor es a , mayor $\phi(a)/\Phi(a)$ y más fuerte el sesgo. En la cohorte 2026-08 la censura alcanzó el 73,9%.

Resultado 3 (Magnitud medida). Mediana de días predicha por el AFT censurado: 47,6. Por mínimos cuadrados descartando las censuradas: 23,2. El sesgo es de $-24,4$ días, más de la mitad del valor estimado.

7. Sesgo II: riesgo competitivo

El 18,2% de las unidades no se arrienda: se da de baja. Eso **no es censura**: no es “todavía no se sabe”, es un desenlace observado y definitivo. Existen dos causas con tasas específicas h_1 (arriendo) y h_2 (baja), y la supervivencia depende de ambas:

$$S(t) = \exp\left(-\int_0^t [h_1(u) + h_2(u)] du\right), \quad F_1(t) = \int_0^t S(u^-) h_1(u) du. \quad (11)$$

F_1 es la **incidencia acumulada**: la probabilidad de que la unidad se arriende antes de t en el mundo real, donde puede darse de baja antes. Si en cambio se trata la baja como censura y se calcula $1 - \exp(-\int_0^t h_1)$, se está estimando la probabilidad de arriendo en un mundo contrafactual sin bajas. La desigualdad tiene una sola dirección:

$$1 - \exp\left(-\int_0^t h_1(u) du\right) \geq \int_0^t S(u^-) h_1(u) du = F_1(t), \quad (12)$$

cuya demostración es inmediata: $\exp(-\int(h_1 + h_2)) \leq \exp(-\int h_1)$ porque $h_2 \geq 0$. Tratar la baja como censura **siempre sobreestima** la probabilidad de arriendo. La formulación de referencia para regresión sobre la incidencia acumulada es Fine y Gray [4].

Observación 3 (Dónde muere). A 20 días la masa de bajas es pequeña: $\mathbb{P}(\text{arrendada}) = 0,263$ frente a $\mathbb{P}(\text{baja}) = 0,024$. Pero la baja no está repartida uniformemente: se concentra en los segmentos lentos, con un 43% de censura en comunas como Cerrillos y San Joaquín. El sesgo es mayor exactamente donde el modelo debe advertir un problema.

8. El precio de referencia y sus dos sesgos

El precio en nivel no sirve: entre deciles extremos, las unidades caras se colocan 10,9 días *más rápido*, porque las comunas caras son las líquidas. El precio solo informa relativo a lo que la unidad debería costar. De ahí la estructura en dos etapas, que sigue a Andersson [1]:

$$(i) \quad \log P_i = w_i' \gamma + u_i, \quad (13)$$

$$(ii) \quad \log T_i = \alpha \hat{u}_i + x_i' \beta + \sigma \varepsilon_i. \quad (14)$$

La primera etapa es un modelo hedónico del precio; el residuo $\hat{u}$ es el *gap*. Por construcción $\hat{u}$ es ortogonal a w en la muestra de ajuste: es **la componente del precio que los atributos no explican**, es decir la parte discrecional de la decisión de *pricing*. La justificación teórica del canal es la búsqueda competitiva de Díaz y Jerez [3]: publicando precios más bajos, el vendedor atrae más visitas y coloca más rápido.

8.1. Regresor generado

$\hat{u}$ no se observa, se estima. Eso rompe dos cosas distintas, y conviene no confundirlas porque tienen remedios distintos.

(a) Inferencia. Los errores estándar de la segunda etapa están subestimados porque ignoran la incertidumbre de $\hat{\gamma}$: es el problema de Pagan [13]. La corrección es aplicar *bootstrap* al procedimiento completo —reestimando (13) dentro de cada réplica— o la corrección analítica de Murphy y Topel [12]. Es lo que hacen Allen, Rutherford y Thomson [5] sobre 20.131 arriendos de Dallas con esta misma especificación en dos etapas.

(b) Sesgo. Si $\hat{u} = u - \xi$ con $\xi = \log \hat{P} - \log P^*$ el error de estimación de la primera etapa, se trata de error de medición clásico en el regresor y

$$\text{plim } \hat{\alpha} = \alpha \cdot \underbrace{\frac{\text{Var}(u)}{\text{Var}(u) + \text{Var}(\xi)}}_{\lambda} < \alpha. \quad (15)$$

Atenuación hacia cero: cuanto peor el modelo de precio, más se diluye el efecto estimado del *gap*. λ es la *razón de confiabilidad* [7].

Observación 4 (El *bootstrap* no corrige (b)). Un *bootstrap* reproduce en cada réplica el sesgo que tenga el estimador. Si $\hat{\alpha}$ está atenuado, las B réplicas están atenuadas y el resultado es un intervalo angosto alrededor del número equivocado: precisión sobre algo sesgado. El resultado de Pagan es sobre la **varianza**, no sobre el punto. Allen et al. tampoco corrigen la atenuación.

8.2. Identificación de $\text{Var}(\xi)$ y corrección de la atenuación

Para aplicar (15) hace falta $\text{Var}(\xi)$, y el obstáculo es que **no se identifica con el residuo del hedónico**: ese residuo *es* $\hat{u}$, y bajo $\xi \perp u$ ya trae las dos varianzas sumadas,

$$\text{Var}(\hat{u}) = \text{Var}(u) + \text{Var}(\xi). \quad (16)$$

Hace falta una fuente de variación que mueva $\hat{P}$ dejando P^* fijo. El propio *bootstrap* de (a) la provee. Para una unidad **fija** i , se recalcula el *gap* en cada réplica con el hedónico reajustado sobre la remuestra. Como u_i no cambia entre réplicas,

$$\hat{u}_i^{(b)} - \hat{u}_i = -(\log \hat{P}^{(b)}(w_i) - \log \hat{P}(w_i)), \quad (17)$$

de modo que la dispersión entre réplicas aísla exactamente la variabilidad de la primera etapa y

$$\widehat{\text{Var}}(\xi) = \frac{1}{n} \sum_{i=1}^n \text{Var}_b(\hat{u}_i^{(b)}), \quad \hat{\lambda} = 1 - \frac{\widehat{\text{Var}}(\xi)}{\text{Var}(\hat{u})}, \quad \hat{\alpha}_{\text{corr}} = \frac{\hat{\alpha}}{\hat{\lambda}}. \quad (18)$$

El mismo factor $1/\hat{\lambda}$ se aplica a los extremos del intervalo. Es una corrección de primer orden: trata $\hat{\lambda}$ como conocido e ignora su propia varianza de muestreo, lo que subestima levemente la amplitud del intervalo corregido.

Resultado 4 (Qué corrige y qué no). $\hat{\alpha}/\hat{\lambda}$ sigue siendo una **cota inferior**, por dos razones independientes:

1. El *bootstrap* mide el error de **estimación** de $\hat{P}$, no el de **especificación**. Si el hedónico está mal especificado, $\hat{P}$ es sesgado para P^* y esa componente de ξ no aparece en la dispersión entre réplicas —es común a todas ellas—. Luego $\widehat{\text{Var}}(\xi)$ es una subestimación, $\hat{\lambda}$ una sobrestimación, y la corrección se queda corta.
2. Corrige la atenuación por medición, no la endogeneidad de la sección siguiente, que empuja en la misma dirección.

Una alternativa sin este límite es SIMEX [6]: se inyecta ruido adicional de varianza conocida $\theta \widehat{\text{Var}}(\xi)$ para $\theta = 0,5, 1, 1,5, 2$, se observa cómo decae $\hat{\alpha}(\theta)$ y se extrapola a $\theta = -1$. Es más robusto a la forma funcional del decaimiento, y también más caro: multiplica por cinco el número de ajustes.

8.3. Endogeneidad: el sesgo que no se corrige

La ecuación estructural es $\log T = \alpha g + x'\beta + \nu$, donde ν contiene todo lo que hace deseable a una unidad y no se observa: orientación, vista, luz, estado de las terminaciones. Pero **quien fija el precio sí observa parte de ν** . La regla de *pricing* es $g = f(x, \nu, \eta)$, y en consecuencia

$$\text{plim } \hat{\alpha} = \alpha + \frac{\text{Cov}(g, \nu)}{\text{Var}(g | x)}. \quad (19)$$

El signo del segundo término admite un argumento. Dos historias plausibles, y ambas apuntan en la misma dirección:

- La unidad es mejor de lo que registran los datos (ν bajo, se coloca rápido) y quien fija el precio lo advierte y cobra más (g alto) $\Rightarrow \text{Cov}(g, \nu) < 0$.
- La unidad es peor de lo que registran los datos (ν alto, lenta) y se le asigna un precio de castigo (g bajo) $\Rightarrow \text{Cov}(g, \nu) < 0$ también.

Resultado 5 (Dirección del sesgo de endogeneidad). Con $\text{Cov}(g, \nu) < 0$ y $\alpha > 0$, la estimación **subestima** el efecto del sobreprecio. Sumado a la atenuación de (15), que opera en la misma dirección, $\hat{\alpha}$ es plausiblemente una **cota inferior** del daño real de publicar caro.

Es un argumento de signo, no una demostración: descansa en que la regla de *pricing* no asigne precios altos a unidades sistemáticamente peores. Pero es la dirección conservadora, lo que significa que el modelo no exagera el efecto del precio.

Corregirlo exigiría variación exógena de precios: un experimento, o un cambio de política que haya movido precios por razones ajenas a la unidad. Es el problema que formaliza Stein [15]: el precio de lista es una elección estratégica del vendedor, no un tratamiento asignado. **Reducir el precio de una unidad no produce mecánicamente el cambio de velocidad que sugiere el coeficiente.**

Observación 5 (Causalidad inversa dentro de la ventana). El 37,3% de las unidades tuvo una rebaja durante la vacancia, y esas tardan 53 días de mediana frente a 24. Eso *no* es evidencia de que rebajar no sirva: se rebaja *porque* no se arrienda. El *gap* se mide con el precio del día 0 precisamente para evitar esta contaminación, pero la protección es parcial: si el precio inicial ya anticipaba un problema, la contaminación entra igualmente.

9. Sesgo IV: codificación del efecto de edificio

Hay 796 edificios y 3.889 unidades: como variables indicadoras es inviable. Se utiliza la media del objetivo por edificio, encogida hacia la media global —un estimador de Bayes empírico—:

$$\text{TE}_j = \frac{n_j \bar{y}_j + m \bar{y}}{n_j + m} \implies \mathbb{E}[\text{TE}_j] - \theta_j = \frac{m}{n_j + m} (\bar{y} - \theta_j). \quad (20)$$

Sesgo deliberado hacia la media global, que se desvanece a medida que n_j crece, a cambio de reducir la varianza por un factor $(n_j/(n_j + m))^2$. El m óptimo en error cuadrático medio es aproximadamente el cociente entre la varianza intra-edificio y la varianza entre edificios; en la implementación está fijado en 20.

Observación 6 (El sesgo peligroso es el otro). Si el código del edificio j se calcula empleando el y_i de la propia observación i , el regresor queda correlacionado con el error por construcción y el ajuste dentro de muestra se infla de manera espectacular. Es la forma más común de inflar artificialmente un AUC. La codificación se calcula fuera de pliegue —cinco particiones internas dentro del conjunto de entrenamiento— precisamente por esto. Nótese además que para un edificio nuevo sin historial el código colapsa al valor previo global: el modelo pierde su variable más fuerte exactamente donde más se la quería.

10. Sesgo V: el esquema de validación

La validación cruzada aleatoria estima el error esperado bajo el supuesto de que las observaciones son extracciones independientes de una distribución fija. Aquí ese supuesto falla por dos vías simultáneas.

Correlación intra-edificio. Dos unidades de la misma torre comparten ubicación, administración y política de precio. El tamaño de muestra efectivo se aproxima al número de edificios más que al de unidades, y con partición aleatoria el mismo edificio aparece en entrenamiento y en prueba.

No estacionariedad. La distribución conjunta se desplaza entre cohortes: las visitas de la primera semana oscilan entre 4,7 y 13,3 según el mes.

Esquema	AUC@20	Supuesto que emplea
Validación cruzada aleatoria	0,767	observaciones i.i.d.: falso por ambas vías
<i>GroupKFold</i> por edificio	0,731	corrige el conglomerado, no la deriva
<i>Forward</i> por cohorte	0,705	reproduce el uso real: pasado → mes siguiente

Tabla 1: Efecto del esquema de validación sobre el desempeño estimado.

La descomposición es limpia: 0,036 de fuga por conglomerado y 0,026 de deriva temporal. Los 0,062 conjuntos son el margen por el cual un proyecto validado con partición aleatoria promete un desempeño que no obtendrá.

11. Calibración

La regresión de calibración de Cox contrasta el *nivel* de la probabilidad, no su orden:

$$\text{logit } \mathbb{P}(Y = 1 \mid \hat{p}) = a + b \cdot \text{logit}(\hat{p}). \quad (21)$$

Con $b = 1$ y $a = 0$ la probabilidad significa lo que declara. Un $b < 1$ indica predicciones sobredispersas: los extremos exageran. Las pendientes medidas fueron 0,487 para la logística, 0,717 para el AFT y 0,725 para el modelo de riesgos competitivos; la primera lo suficientemente baja como para que sus probabilidades no sean publicables.

El escalamiento de Platt [14] lo corrige reajustando a y b , y esa corrección **también se estima hacia adelante**: sobre las cohortes anteriores, aplicada a la siguiente. Ajustarla sobre las mismas predicciones que después se evalúan produce una pendiente de 1,000 por construcción y carece de contenido.

Observación 7 (Dos verificaciones). La transformación es monótona, de modo que el AUC *dentro* de una cohorte no puede cambiar; ésa es la comprobación de que la implementación es correcta. Y si la pendiente estimada resulta negativa, el mapeo invierte el orden y el *score* recalibrado queda peor que el original: en ese caso la cohorte se deja sin recalibrar.

12. El techo estocástico

Parte del error no es eliminable con ninguna variable adicional, porque el desenlace *es* un tiempo de espera aleatorio. Para el error cuadrático de la probabilidad la descomposición es exacta, con π la probabilidad verdadera:

$$\mathbb{E}[(Y - \hat{p})^2] = \underbrace{\mathbb{E}[\pi(1 - \pi)]}_{\text{irreducible}} + \underbrace{\mathbb{E}[(\pi - \hat{p})^2]}_{\text{error del modelo}}. \quad (22)$$

Para el ordenamiento el resultado es igual de nítido. Consideremos dos unidades con medias μ_1 y μ_2 , cada una con su propio choque log-normal:

$$\mathbb{P}(T_1 < T_2 \mid \mu_1, \mu_2) = \mathbb{P}(\sigma(\varepsilon_1 - \varepsilon_2) < \mu_2 - \mu_1) = \Phi\left(\frac{\mu_2 - \mu_1}{\sigma\sqrt{2}}\right). \quad (23)$$

Resultado 6 (Lo que implica (23)). La concordancia máxima alcanzable depende **única-mente del cociente entre la dispersión de las medias predichas y σ** . No del algoritmo empleado ni del tamaño de muestra. Si σ es grande respecto de cuánto se separan las unidades entre sí, ni un modelo perfecto ordena bien.

Métrica	Observado	Techo	% capturado
Índice de concordancia	0,685	0,713	87 %
AUC@20	0,725	0,763	86 %

Tabla 2: Desempeño observado frente al máximo alcanzable, estimado por simulación desde el propio modelo ajustado.

La simulación de sensibilidad lo confirma: con σ reducido a la mitad el techo del índice de concordancia subiría a 0,811. El límite lo impone el ruido del proceso, no el algoritmo. Andersson [1] realiza el mismo cálculo con 20.000 unidades en Japón y obtiene un techo de aproximadamente 0,66 frente a un índice logrado de 0,63. El índice utilizado es el de Harrell *et al.* [11], en la variante consistente bajo censura de Uno *et al.* [16].

Observación 8 (Qué no dice este techo). Se calcula bajo el supuesto de que el modelo está correctamente especificado, es decir que las $\hat{p}$ son las verdaderas. Si faltan variables, las probabilidades verdaderas se separan más entre unidades y **el techo real es más alto**. La conclusión correcta no es “no se puede predecir mejor” sino “no se puede predecir mejor *con esta información*”.

13. Inventario de sesgos

Sesgo	Dir.	Magnitud	Estado
Censura	↓	−24,4 días	corregido: verosimilitud (7)
Riesgo competitivo	↑	0,024 a 20 d	corregido: incidencia acumulada (11)
Fuga en la codificación	↑	—	corregido: codificación fuera de pliegue
Validación aleatoria	↑	+0,062	corregido: <i>forward</i> por cohorte
Sesgo de longitud	↑	73,9 % censura	corregido: se excluyen cohortes con observabilidad < 0,90
Descalibración	↑	$b = 0,717$	corregido: Platt hacia adelante (21)
<i>Shrinkage ridge</i>	↓	EPV = 22	deliberado: se acepta por varianza
Reg. generado: inferencia	—	se_{comp}/se_{ing}	corregido: <i>bootstrap</i> de ambas etapas
Reg. generado: atenuación	↓	$\hat{\lambda}$, ec. (18)	parcial: $\hat{\alpha}/\hat{\lambda}$ sigue siendo cota inferior
Endogeneidad del precio	↓	—	vivo: requiere variación exógena
Selección de muestra	○	91 % de las LPA	vivo: se declara, no se corrige

Tabla 3: Inventario de sesgos. ↓ atenúa o subestima; ↑ infla o sobreestima; ○ afecta validez externa, no interna.

Los ocho primeros están incorporados al modelo. La atenuación por regresor generado está corregida solo en parte: (18) recupera la componente atribuible al error de estimación de la primera etapa, no la que viene de su especificación. Los dos últimos no son corregibles con métodos estadísticos sobre estos datos, y por lo tanto deben declararse en cualquier informe que utilice estos números.

Los sesgos que siguen afectando al coeficiente de precio —la atenuación residual y la endogeneidad— **operan ambos hacia cero**. Ese es el hallazgo más tranquilizador del inventario: el modelo no exagera el efecto del precio, lo subestima. El resultado de la ablación —eliminar el *gap* cuesta 0,052 de AUC— es entonces un piso y no un techo.

El sesgo de selección es de otra naturaleza: no deforma nada dentro de la muestra, define a quién aplica el modelo. Cubre unidades que alcanzan el estado “lista para arrendar” con historial de precio. Quedan fuera las 1.733 unidades que alcanzaron el estado “arrendado” sin pasar nunca por publicación —ingresaron ya ocupadas o fueron asignadas directamente— y aproximadamente el 9 % sin historial de precio.

14. Síntesis

1. **El modelo estima una tasa, no un promedio**, porque una de cada cinco unidades carece de desenlace y descartarlas sesga la predicción en 24 días.
2. **Un coeficiente es una semi-elasticidad sobre los días**, y su efecto sobre la probabilidad publicada es máximo cuando la mediana predicha de la unidad coincide con el horizonte, según (5). La palanca de precio rinde en el centro de la distribución, no en la cola.
3. **El efecto del precio está subestimado, no exagerado**, porque los sesgos que permanecen atenúan hacia cero. El *bootstrap* de dos etapas corrige la inferencia y (18) recupera parte de la atenuación, pero ni uno ni otro tocan la endogeneidad. Sigue siendo,

por tanto, una asociación: para afirmar que rebajar acelera se requiere variación exógena que estos datos no contienen.

Referencias

- [1] Andersson, P. (2025). *Predicting the vacancy duration of Japanese rental apartments*. Proceedings of the 39th Annual Conference of the Japanese Society for Artificial Intelligence, 204-OS-21a-03.
- [2] Deng, Y., Gabriel, S. A. y Nothhaft, F. E. (2003). Duration of residence in the rental housing market. *Journal of Real Estate Finance and Economics*, 26(2/3), 267–285.
- [3] Díaz, A. y Jerez, B. (2010). *House prices, sales and time on the market: a search-theoretic framework*. Universidad Carlos III de Madrid, Working Paper Economic Series 10-33.
- [4] Fine, J. P. y Gray, R. J. (1999). A proportional hazards model for the subdistribution of a competing risk. *Journal of the American Statistical Association*, 94(446), 496–509.
- [5] Allen, M. T., Rutherford, R. C. y Thomson, T. A. (2009). Residential asking rents and time on the market. *Journal of Real Estate Finance and Economics*, 38(4), 351–365.
- [6] Cook, J. R. y Stefanski, L. A. (1994). Simulation-extrapolation estimation in parametric measurement error models. *Journal of the American Statistical Association*, 89(428), 1314–1328.
- [7] Fuller, W. A. (1987). *Measurement Error Models*. Wiley, Nueva York.
- [8] Gdakowicz, A., Putek-Szeląg, E. y Bas, M. (2023). Duration of the rental offer for residential property. *Real Estate Management and Valuation*, 31(2), 82–91.
- [9] Gdakowicz, A. y Putek-Szeląg, E. (2025). The impact of selected attributes of new residential properties on the timing of their sale. *Real Estate Management and Valuation*, 33(3), 60–74.
- [10] Han, A. y Hausman, J. A. (1990). Flexible parametric estimation of duration and competing risk models. *Journal of Applied Econometrics*, 5(1), 1–28.
- [11] Harrell, F. E., Califf, R. M., Pryor, D. B., Lee, K. L. y Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18), 2543–2546.
- [12] Murphy, K. M. y Topel, R. H. (1985). Estimation and inference in two-step econometric models. *Journal of Business & Economic Statistics*, 3(4), 370–379.
- [13] Pagan, A. (1984). Econometric issues in the analysis of regressions with generated regressors. *International Economic Review*, 25(1), 221–247.
- [14] Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En *Advances in Large Margin Classifiers*, MIT Press.
- [15] Stein, J. C. (1995). Prices and trading volume in the housing market: a model with downpayment effects. *Quarterly Journal of Economics*, 110(2), 379–406. (Versión previa: NBER Working Paper 4373, 1993.)
- [16] Uno, H., Cai, T., Pencina, M. J., D’Agostino, R. B. y Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10), 1105–1117.

- [17] van Smeden, M., Moons, K. G. M., de Groot, J. A. H., Collins, G. S., Altman, D. G., Eijkemans, M. J. C. y Reitsma, J. B. (2019). Sample size for binary logistic prediction models: beyond events per variable criteria. *Statistical Methods in Medical Research*, 28(8), 2455–2474.